

DIA 2

Construção e validação da estratégia de busca piloto

Retrieval-Augmented Generation em Domínios Ambientais e de Sustentabilidade

Plano operacional para uma única revisora - revisão sistemática em 30 dias

STATUS: Gate do Dia 1 aprovado. RQ1-RQ4, definição de RAG e definição do domínio foram confirmadas pela revisora.

Objetivo do Dia 2: transformar o escopo conceitual aprovado em uma estratégia de busca piloto documentada, testável e adaptável às três bases iniciais, sem ainda executar a busca definitiva.

Versão operacional - Outubro de 2026

1. O que já está fechado antes de começar

O Dia 2 começa com decisões conceituais já aprovadas. Elas não devem ser reabertas apenas porque uma busca piloto retorna muitos ou poucos registros. A função da busca piloto é testar a estratégia de recuperação, não redefinir o objeto científico da revisão.

Item	Decisão atual	Status
Objeto principal	Retrieval-Augmented Generation (RAG).	Fechado
Contexto de aplicação	Domínios ambientais e de sustentabilidade.	Fechado
RQ1-RQ4	Arquitetura; componentes; avaliação; evidência experimental.	Fechado
Bases iniciais	Scopus, IEEE Xplore e ACM Digital Library.	Fechado em princípio
Período	2020 até a data da busca final.	Fechado em princípio
Corpus principal	Estudos peer-reviewed.	Fechado em princípio
CI/CE	Versão v0.1.	Ainda será calibrada
String de busca	Rascunho v0.1.	NÃO congelada

REGRA DO DIA 2: não mudar RQs nem ampliar o domínio apenas para “fazer caber” um artigo específico.

2. Meta concreta do Dia 2

Ao final do dia, você deve ter uma string piloto v0.2 documentada, três execuções piloto registradas e evidência suficiente para dizer se a estratégia é sensível ao conjunto conhecido de estudos sem produzir um volume obviamente inviável de ruído.

- Construir os blocos conceituais da busca: RAG + domínio ambiental/sustentabilidade.
- Definir um conjunto-semente de estudos conhecidos e claramente relevantes.
- Adaptar a busca à sintaxe e aos campos disponíveis em Scopus, IEEE Xplore e ACM DL.
- Executar apenas buscas piloto e registrar data, string, filtros, quantidade retornada e arquivo exportado.
- Distinguir “artigo não indexado na base” de “artigo indexado, mas perdido pela string”.
- Registrar qualquer alteração em amendments.md e nunca sobrescrever silenciosamente a versão anterior.

3. O que NÃO deve ser feito hoje

- Não executar a busca definitiva.
- Não iniciar a triagem completa do corpus.
- Não aplicar snowballing.
- Não começar extração dos estudos.
- Não adicionar dezenas de termos de aplicação (flood, wildfire, ocean, agriculture etc.) sem evidência de que são necessários.
- Não usar o número de resultados como único critério para considerar a string boa ou ruim.

4. Modelo conceitual da estratégia de busca

A estratégia deve ser construída em dois blocos principais conectados por AND. Dentro de cada bloco, sinônimos e variantes são conectados por OR.

BLOCO A - RAG AND BLOCO B - DOMÍNIO AMBIENTAL / SUSTENTABILIDADE

4.1 Bloco A - Retrieval-Augmented Generation

A versão piloto deve priorizar expressões que identifiquem explicitamente RAG e suas variantes. O acrônimo RAG isolado é ambíguo; quando utilizado, deve ser condicionado à presença de LLM/large language model.

```
("retrieval augmented generation"
OR "retrieval-augmented generation"
OR "retrieval enhanced generation"
OR "retrieval-enhanced generation"
OR "GraphRAG"
OR "graph RAG"
OR "agentic RAG"
OR "multimodal RAG"
OR ("RAG" AND ("large language model*" OR LLM*)))
```

4.2 Bloco B - núcleo ambiental e de sustentabilidade

Comece com um núcleo curto e semanticamente abrangente. Termos adicionais só entram se a busca piloto demonstrar uma lacuna real de recuperação.

```
(environment*
OR sustainab*
OR climat*
OR ecolog*)
```

4.3 String conceitual piloto v0.1

```
(
  "retrieval augmented generation"
  OR "retrieval-augmented generation"
  OR "retrieval enhanced generation"
  OR "retrieval-enhanced generation"
  OR "GraphRAG"
  OR "graph RAG"
  OR "agentic RAG"
  OR "multimodal RAG"
  OR ("RAG" AND ("large language model*" OR LLM*))
)
AND
(
  environment*
  OR sustainab*
  OR climat*
  OR ecolog*
)
```

Essa string é o ponto de partida, não o resultado final do Dia 2.

4.4 Termos candidatos à expansão - NÃO adicionar automaticamente

Conceito	Termo candidato	Quando considerar
Biodiversidade	biodivers*	Se estudos ambientais relevantes forem perdidos.
Conservação	conservation	Se o núcleo não recuperar trabalhos de conservação.
Recursos naturais	"natural resource*"	Útil para gestão sustentável de recursos.
Hidrologia	hydrolog*	Somente se houver perda sistemática de estudos hídricos relevantes.

Conceito	Termo candidato	Quando considerar
Oceanos	ocean* OR oceanograph*	Somente se trabalhos oceânicos-alvo não contiverem termos do núcleo.
Geociências	geoscien* OR "earth science**"	Usar com cautela: pode trazer forte ruído não ambiental.
Sensoriamento remoto	"remote sensing"	Candidato de alto ruído; adicionar apenas com justificativa.

5. Criar o conjunto-semente de calibração

O conjunto-semente não é um “gold standard” da literatura. Ele é apenas um conjunto de estudos previamente conhecidos, usado para testar se a string consegue recuperar exemplos que certamente deveriam ser alcançáveis pelo protocolo.

Meta recomendada: 8 a 12 estudos-semente, cobrindo diferentes subdomínios e diferentes estilos de arquitetura RAG.

ID	Estudo-semente	Ano	Cobertura
S01	A Hybrid Question Answering Model with Ontological Integration for Environmental Information	2024	Informação ambiental / ontologia
S02	A LLM-Based Platform For Flood Risk Education and Weather Alerts in SIDS	2024	Hidrometeorologia / risco
S03	My Climate Advisor: An Application of NLP in Climate Adaptation for Agriculture	2024	Agricultura / adaptação
S04	ClimateGPT: Towards AI Synthesizing Interdisciplinary Research on Climate Change	2024	Mudança climática / síntese
S05	SDG target detection in environmental reports using Retrieval-augmented Generation with LLMs	2024	Relatórios ambientais / ODS
S06	A Self-Improving, RAG-Enhanced Framework for Automatic Knowledge Graph Construction from Climate Event News	2025	Eventos climáticos / KG
S07	Domain-Specific Question-Answering Systems: A Case Study of a Carbon Neutrality Knowledge Base	2025	Neutralidade de carbono
S08	REMFLOW: RAG-enhanced multi-factor rainfall flooding warning in sponge airports via large language model	2025	Inundação / alerta
S09	AI-Driven Wildfire Reasoning Utilizing Multimodal Retrieval-Augmented Generation	2025	Incêndios / multimodal
S10	SeaSense: An AI-Powered Conversational Interface for Oceanographic Data Analysis Using Retrieval Augmented Generation Architecture	2026	Oceanografia / dados
S11	Multimodal Urban Heat Island Mitigation via Knowledge Reasoning and Geospatial Optimisation	2026	Ilha de calor / geoespacial

ID	Estudo-semente	Ano	Cobertura
S12	Using Large Language Models to Detect and Debunk Climate Change Misinformation	2026	Desinformação climática

Esses títulos podem ser substituídos por outros estudos conhecidos, desde que você mantenha a justificativa e a cobertura de subdomínios. O objetivo é testar a estratégia, não garantir que esses 12 sejam o corpus final.

6. Como validar cada estudo-semente corretamente

Um estudo não recuperado pela string pode estar simplesmente fora da cobertura daquela base. Por isso, todo “miss” precisa ser diagnosticado antes de alterar a string.

1. Execute a string piloto na base.
2. Verifique quais estudos-semente aparecem nos resultados.
3. Para cada estudo-semente ausente, faça uma busca por título exato na mesma base.
4. Se o título exato também não existir na base: marque not_indexed. Isso NÃO é falha da string.
5. Se o título exato existir, mas a string não recuperá-lo: marque query_miss. Esse caso pode justificar ajuste na string.
6. Registre qual termo do título/resumo/keywords poderia explicar o miss antes de adicionar qualquer novo sinônimo.

NÃO altere a string para recuperar um artigo que nem sequer está indexado na base.

6.1 Indicador interno de calibração

Para cada base, você pode calcular uma taxa simples de recuperação do conjunto-semente indexado:

$$\text{taxa_semente} = \frac{\text{estudos-semente recuperados pela string}}{\text{estudos-semente confirmados como indexados na base}}$$

Essa taxa NÃO é recall da literatura inteira. É apenas um diagnóstico interno da busca piloto e não deve ser reportada como medida formal de cobertura bibliográfica.

7. Execução piloto nas três bases

Use a mesma lógica conceitual em todas as bases, mas preserve a sintaxe exata executada em cada interface. A reprodutibilidade depende do registro literal da consulta e dos filtros, não de fingir que todas as bases usam a mesma linguagem.

7.1 Scopus

Use Advanced Search e limite a busca conceitual a título, resumo e palavras-chave com TITLE-ABS-KEY. O suporte oficial do Scopus confirma esse campo combinado e o uso de operadores booleanos.

```
TITLE-ABS-KEY(
  ("retrieval augmented generation" OR "retrieval-augmented generation"
   OR "retrieval enhanced generation" OR "retrieval-enhanced generation"
   OR "GraphRAG" OR "graph RAG" OR "agentic RAG" OR "multimodal RAG"
   OR ("RAG" AND ("large language model*" OR LLM*)))
  AND
  (environment* OR sustainab* OR climat* OR ecolog*)
)
AND PUBYEAR > 2019
```

No piloto, registre separadamente qualquer filtro de tipo documental aplicado na interface. Evite incorporar filtros que ainda não foram decididos ao texto da query.

7.2 IEEE Xplore

O IEEE Xplore aceita Boolean em Command Search; os operadores devem aparecer em maiúsculas e a plataforma trabalha com campos de dados. Para o piloto, prefira limitar a consulta a metadados/título-resumo quando possível e salve a expressão literal que a interface realmente executou.

```
((("retrieval augmented generation" OR "retrieval-augmented generation" OR "retrieval enhanced generation" OR "retrieval-enhanced generation" OR "GraphRAG" OR "graph RAG" OR "agentic RAG" OR "multimodal RAG") AND (environment* OR sustainab* OR climat* OR ecolog*))
```

Se precisar usar o acrônimo RAG, combine-o com "large language model"/LLM para reduzir ambiguidade. Não exceda os limites de termos por cláusula da interface; se necessário, teste em linhas/blocos separados e registre exatamente como foi feito.

7.3 ACM Digital Library

Use Advanced Search, preferencialmente sobre metadados/abstract e não sobre Full Text para evitar um aumento desnecessário de ruído. A interface permite operadores Boolean e filtros por data.

```
("retrieval augmented generation" OR "retrieval-augmented generation" OR "retrieval enhanced generation" OR "retrieval-enhanced generation" OR "GraphRAG" OR "graph RAG" OR "agentic RAG" OR "multimodal RAG") AND (environment* OR sustainab* OR climat* OR ecolog*)
```

No search_log.csv, registre o campo escolhido na interface (por exemplo, Abstract/Anywhere), porque essa escolha afeta diretamente a reprodutibilidade.

7.4 Fontes operacionais de sintaxe

- Scopus Support Center - Advanced Search / TITLE-ABS-KEY - consulta em outubro de 2026.
- IEEE Xplore - Advanced/Command Search - operadores Boolean em maiúsculas e busca por campos.
- ACM Digital Library - Advanced Search - Boolean, seleção de campos e intervalo de publicação.

8. Como avaliar o ruído sem transformar o Dia 2 em screening

O objetivo não é estimar precisão formal da revisão. Você só precisa saber se a string retorna resultados majoritariamente plausíveis ou se está claramente dominada por falsos positivos.

- Se a base retornar até 20 registros, inspecione todos rapidamente por título/resumo.
- Se retornar mais de 20, inspecione uma pequena amostra fixa de 15-20 registros e anote quantos parecem claramente aderentes ao domínio e ao RAG.
- Use essa amostra apenas como diagnóstico de ruído; não a confunda com a triagem oficial.
- Não exclua termos somente porque a amostra inicial tem alguns falsos positivos. Procure padrões de ruído repetidos.

9. Regras de decisão para alterar a string

Decisão	Regra
Adicionar termo	Existe query_miss confirmado em estudo-semente indexado E o termo é conceitualmente geral, não específico de um único caso.
Manter termo	Recupera estudos relevantes ou representa conceito central do escopo, mesmo com algum ruído tolerável.
Remover termo	Produz ruído sistemático e há evidência de que sua remoção não elimina estudos-semente ou classes relevantes.
Não adicionar	Termos muito específicos de aplicação (ex.: wildfire, flood, ocean) usados apenas para "forçar" a recuperação de um artigo.
Criar v0.2	Qualquer alteração substancial na string após o piloto.
Registrar amendment	Se a alteração modifica uma decisão metodológica além da string, por exemplo inclusão de nova base ou redefinição de critério.

A string final deve ser suficientemente sensível para o escopo e suficientemente específica para ser executável por uma única revisora em um mês.

10. Arquivos que devem ser atualizados/criados no Dia 2

Além dos arquivos já criados no Dia 1, o Dia 2 deve deixar uma trilha explícita da calibração da busca.

```
rag-environment-sustainability-systematic-review/
├── protocol/
│   └── amendments.md           [atualizar se necessário]
├── search/
│   ├── search_strings.md       [atualizar para v0.2 se houver mudança]
│   ├── search_log.csv          [registrar cada busca piloto]
│   ├── pilot_validation.csv     [NOVO]
│   ├── pilot_notes.md          [NOVO]
│   └── exports/
│       └── pilot/              [NOVO]
│           ├── scopus/
│           ├── ieee/
│           └── acm/
└── ...
```

10.1 pilot_validation.csv

```
seed_id,title,database,indexed,query_retrieved,status,diagnostic_term,notes
```

Valores sugeridos para status: recovered | query_miss | not_indexed | uncertain.

10.2 pilot_notes.md

```
# Notas da busca piloto

## Scopus
- Data/hora:
- String executada:
- Resultados:
- Seeds recuperados:
- Seeds perdidos e diagnóstico:
- Padrões de ruído:

## IEEE Xplore
...

## ACM Digital Library
...

## Decisão ao final do Dia 2
- String mantida/alterada:
- Nova versão:
- Justificativa:
```

10.3 search_log.csv - exemplo de preenchimento

database	date	query_version	query	filters	results	export_file
Scopus	2026-10-__	v0.1	[string literal]	2020-presente; piloto	[n]	exports/pilot/ scopus/...
IEEE Xplore	2026-10-__	v0.1	[string literal]	2020-presente; piloto	[n]	exports/pilot/ieee/...
ACM DL	2026-10-__	v0.1	[string literal]	2020-presente; piloto	[n]	exports/pilot/acm/...

11. Sequência prática do Dia 2

Etapa	Tempo estimado	Entrega
Etapa 1	30-45 min	Revisar search_strings.md e confirmar a string conceitual v0.1.
Etapa 2	30-45 min	Montar pilot_validation.csv e cadastrar 8-12 estudos-semente.
Etapa 3	60-90 min	Executar piloto na Scopus; diagnosticar seeds ausentes.
Etapa 4	45-75 min	Executar piloto no IEEE Xplore; registrar sintaxe e resultados.
Etapa 5	45-75 min	Executar piloto na ACM DL; registrar campo e resultados.
Etapa 6	45-60 min	Comparar query_miss, not_indexed e padrões de ruído.
Etapa 7	30-45 min	Decidir se cria v0.2; registrar alterações e salvar exports brutos.

Os tempos são apenas uma referência operacional. O critério de encerramento é documental, não cronológico.

12. Checklist de encerramento do Dia 2

- ☐ String conceitual v0.1 revisada.
- ☐ Conjunto-semente de 8-12 estudos registrado.
- ☐ pilot_validation.csv criado.
- ☐ Busca piloto executada na Scopus e registrada.
- ☐ Busca piloto executada no IEEE Xplore e registrada.
- ☐ Busca piloto executada na ACM Digital Library e registrada.
- ☐ Cada seed ausente foi classificado como query_miss, not_indexed ou uncertain.
- ☐ search_log.csv contém uma linha para cada execução piloto.
- ☐ Arquivos brutos do piloto foram preservados em exports/pilot/.
- ☐ Padrões de ruído foram anotados sem iniciar screening formal.
- ☐ Toda mudança na string recebeu uma nova versão.
- ☐ Alterações metodológicas, se houver, foram registradas em amendments.md.
- ☐ Nenhuma busca definitiva foi executada.

GATE DO DIA 2: você só avança quando consegue demonstrar, com registros, quais estudos-semente a string recupera, quais perdas decorrem de indexação e quais perdas decorrem da própria consulta; além disso, deve existir uma versão explícita da string que seguirá para a calibração do protocolo.

13. O que acontece no Dia 3

No Dia 3, a string selecionada no piloto será usada junto a um pequeno conjunto de 15-20 registros para calibrar os critérios CI/CE e testar consistência intra-revisora. Somente depois dessa calibração o protocolo deverá ser promovido de v0.1 para v1.0 e a busca definitiva poderá ser preparada.

DIA 2 termina com uma string justificável, versionada e testada.