

ROTEIRO COMPLETO - DIA 4

Busca definitiva, exportacao, consolidacao e deduplicacao

Projeto: Revisao Sistemática sobre Retrieval-Augmented Generation em Domínios Ambientais e de Sustentabilidade

Objetivo do Dia 4: executar as buscas definitivas com as strings congeladas, preservar os arquivos brutos, consolidar Scopus + IEEE Xplore, documentar a deduplicacao e preparar a base oficial para o screening formal.

1. Resultado esperado ao final do Dia 4

- Busca definitiva executada novamente na Scopus.
- Busca definitiva executada novamente no IEEE Xplore.
- Numeros oficiais de registros recuperados documentados.
- Arquivos brutos exportados e preservados sem edicao.
- search/search_log.csv atualizado.
- Registros das duas bases consolidados.
- Duplicatas identificadas e documentadas.
- Base deduplicada pronta para o screening formal.
- screening/decision_log.csv preparado para uso.

Observacao: o objetivo principal do Dia 4 nao e concluir o screening. Se houver tempo, ele pode ser iniciado, mas o essencial e construir corretamente a base definitiva.

2. Antes de abrir as bases

Confirme que o Gate do Dia 3 esta fechado:

```
protocol/protocol_v1.0.md OK
protocol/amendments.md OK
search/search_strings.md OK
screening/exclusion_codes.md OK
screening/calibration_day3.csv OK
screening/calibration_day3.md OK
extraction/data_dictionary.md OK
quality/quality_assessment.csv OK
```

Regra: a partir daqui, nao altere as strings durante a execucao da busca definitiva. Se surgir um problema grave, registre a alteracao em protocol/amendments.md antes de modifica-las.

3. Prepare a pasta de exportacao

```
search/
exports/
raw/
scopus/
ieee/
processed/
```

raw/ = arquivos exatamente como saíram das bases. Nunca editar.

processed/ = arquivos consolidados, normalizados e deduplicados.

4. Execute a busca definitiva na Scopus

Use exatamente a string congelada v1.0:

```
TITLE-ABS-KEY(
(
"retrieval augmented generation"
OR "retrieval-augmented generation"
OR "retrieval enhanced generation"
OR "retrieval-enhanced generation"
```

```
OR "GraphRAG"
OR "graph RAG"
OR "agentic RAG"
OR "multimodal RAG"
OR ("RAG" AND ("large language model*" OR LLM*))
)
AND
(
environmental
OR climat*
OR ecolog*
)
)
AND PUBYEAR > 2019
```

Nao reutilize automaticamente os 472 registros do piloto. Execute a consulta novamente.

Registre imediatamente:

```
Database: Scopus
Search version: v1.0
Search date:
Search time:
Search string:
Filters:
Results:
```

O valor obtido agora sera o **N inicial oficial da Scopus** para a revisao.

5. Confira os filtros antes da exportacao

- Período: 2020 ate a data da busca definitiva.
- Nao aplicar filtro de Open Access.
- Nao restringir por idioma, area ou tipo documental sem previsao explicita no protocolo.
- A disponibilidade do texto completo sera tratada depois, por CE6.

6. Exporte os resultados da Scopus

Exporte, sempre que disponivel:

- Title
- Authors
- Year
- Abstract
- DOI
- Source title
- Document type
- Author keywords
- Index keywords
- Affiliations
- URL / identifier

Use CSV como arquivo operacional principal. Se a base limitar o numero por exportacao, mantenha os lotes separados em raw/.

```
search/exports/raw/scopus/scopus_v1.0_YYYY-MM-DD.csv
```

ou, se houver lotes:

```
scopus_v1.0_YYYY-MM-DD_part01.csv
scopus_v1.0_YYYY-MM-DD_part02.csv
...
```

7. Preserve evidencia da execucao da Scopus

Salve tambem um TXT com a string exatamente executada:

```
search/exports/raw/scopus/scopus_v1.0_query_YYYY-MM-DD.txt
```

Base: Scopus

Versao: v1.0

Data:

Hora:

Resultados:

STRING:

[consulta executada literalmente]

8. Execute a busca definitiva no IEEE Xplore

Use exatamente a string congelada:

```
(
  "retrieval augmented generation"
  OR "retrieval-augmented generation"
  OR "retrieval enhanced generation"
  OR "retrieval-enhanced generation"
  OR "GraphRAG"
  OR "graph RAG"
  OR "agentic RAG"
  OR "multimodal RAG"
  OR ("RAG" AND ("large language model*" OR LLM*))
)
AND
(
  environmental
  OR climat*
  OR ecolog*
)
```

Nao reutilize automaticamente os 230 registros do piloto. Execute novamente e registre o novo total.

```
Database: IEEE Xplore
Search version: v1.0
Search date:
Search time:
Period:
Filters:
Results:
```

9. Exporte os resultados do IEEE Xplore

- Title
- Authors
- Abstract
- Year
- DOI
- Publication title
- Document type
- Keywords
- URL / identifier

```
search/exports/raw/ieee/ieee_v1.0_YYYY-MM-DD.csv
search/exports/raw/ieee/ieee_v1.0_query_YYYY-MM-DD.txt
```

10. Atualize search/search_log.csv

Os numeros registrados aqui passam a ser os numeros oficiais da busca definitiva.

```
search_id,database,version,date,time,period,filters,results,export_file,status,notes

FINAL_SCOPUS_01,Scopus,v1.0,YYYY-MM-DD,HH:MM,2020-search_date,"PUBYEAR >
2019",XXX,scopus_v1.0_YYYY-MM-DD.csv,definitive,"Final search after protocol freeze"

FINAL_IEEE_01,IEEE
Xplore,v1.0,YYYY-MM-DD,HH:MM,2020-search_date,"2020-search_date",YYY,ieee_v1.0_YYYY-MM-DD.csv,definitive,"Final
search after protocol freeze"
```

Nao apague as linhas antigas do piloto. O arquivo deve permitir distinguir claramente **pilot** de **definitive**.

11. Verifique a integridade dos exports

- Compare o numero de registros exportados com o numero mostrado pela base.
- Confira se title, abstract, DOI e year estao presentes quando disponiveis.
- Se houver grande discrepancia entre total da base e linhas exportadas, investigue antes de continuar.

- Registros sem abstract nao devem ser excluidos automaticamente.

12. Preserve os arquivos raw/

A partir daqui, a pasta raw/ deve ser tratada como somente leitura.

- Nao remover linhas.
- Nao corrigir titulos.
- Nao editar DOI.
- Nao apagar duplicatas.
- Nao alterar encoding de forma destrutiva.

Toda transformacao deve acontecer em copias dentro de search/exports/processed/.

13. Consolide Scopus + IEEE Xplore

Crie:

```
search/exports/processed/all_records_before_dedup.csv
```

Inclua pelo menos uma coluna **source_database** e, se possivel, **source_record_id**.

```
source_database = Scopus
source_database = IEEE Xplore
```

```
Se o mesmo registro aparecer nas duas:
source_database = Scopus;IEEE Xplore
```

14. Normalize apenas para deduplicacao

Crie colunas auxiliares sem substituir os valores originais:

```
doi_normalized
title_normalized
```

DOI: remover prefixos como https://doi.org/ ou doi: e preservar o valor original em outra coluna.

Titulo: criar uma versao auxiliar em lowercase, com espacos duplicados removidos e pontuacao simples normalizada. Nunca substituir o titulo original.

15. Deduplicacao em camadas

- 1. DOI exato.
- 2. Titulo normalizado exato.
- 3. Titulo muito semelhante + mesmos autores/ano.
- 4. Inspecao manual dos casos duvidosos.

Nao remova automaticamente estudos apenas porque os titulos sao parecidos.

16. Duplicata x versao redundante

Mesmo DOI em Scopus e IEEE normalmente representa duplicata bibliografica: manter um unico registro.

Conference paper, journal extension e preprint exigem avaliacao. Nem toda versao relacionada e necessariamente duplicata.

Quando forem efetivamente versoes redundantes do mesmo estudo, utilizar CE5 conforme a politica definida.

17. Registre a deduplicacao

Crie:

```
search/exports/processed/deduplication_log.csv
```

```
duplicate_group_id,kept_record_id,removed_record_id,match_basis,decision,notes
D001,S023,S514,DOI,duplicate,"Same DOI in Scopus and IEEE"
```

Ao final, voce deve conseguir informar:

Scopus: X registros
IEEE Xplore: Y registros
Total bruto: $X + Y$
Duplicatas removidas: D
Registros apos deduplicacao: N

18. Gere a base deduplicada

```
search/exports/processed/records_deduplicated.csv
```

Essa sera a base oficial que entrara no screening.

Mantenha os dados bibliograficos separados das decisoes de screening.

19. Atribua IDs estaveis aos registros

Durante o screening, use:

```
record_id = R0001
record_id = R0002
record_id = R0003
...
```

Reserve S001, S002, ... para os estudos incluidos na fase de extracao.

20. Prepare screening/decision_log.csv

```
record_id,screening_stage,decision,reason_code,confidence,fulltext_needed,notes
```

No primeiro screening:

```
screening_stage = title_abstract
```

Decisoes permitidas:

```
include
exclude
maybe
```

Exemplo:

```
R0001,title_abstract,include,,high,no,"Clear environmental RAG study."
R0002,title_abstract,exclude,CE2,high,no,"Operational environment only."
R0003,title_abstract,maybe,,medium,yes,"Need full text to confirm retrieval is integrated with generation."
```

21. Regras do screening formal

```
E realmente RAG?
->
O dominio e ambiental?
->
E estudo primario?
->
Ha avaliacao empirica?
->
Se nao for possivel determinar com seguranca:
->
maybe
```

Use maybe quando o abstract nao trouxer informacao suficiente, especialmente em RAG baseline, ESG, energia/microgrid, semantic retrieval, agricultura e built environment.

22. Calibracao nao e screening formal

Os 18 registros do Dia 3 foram usados para calibracao. Se reaparecerem na busca definitiva, devem entrar normalmente na base e receber uma decisao formal em screening/decision_log.csv.

23. Ordem das etapas apos a deduplicacao

```
title/abstract
->
include + maybe
->
full text
->
corpus final
->
quality assessment
->
data extraction
```

Nao preencha quality_assessment.csv nem inicie a extracao antes da inclusao final por texto completo.

24. Atualize os numeros do fluxo da revisao

Ao final do Dia 4, voce ja deve ter:

```
Identification

Records identified from:
Scopus = X
IEEE Xplore = Y

Total records = X + Y

Duplicates removed = D

Records after deduplication = N
```

Full-text exclusions, estudos finais incluidos e snowballing ainda nao fazem parte deste fechamento.

25. Nao faca snowballing ainda

Backward e forward snowballing devem ocorrer depois da definicao do conjunto elegivel proveniente das buscas tradicionais, conforme o protocolo.

26. Estrutura esperada ao final do Dia 4

```
search/
search_strings.md
search_log.csv
exports/
raw/
scopus/
scopus_v1.0_YYYY-MM-DD.csv
scopus_v1.0_query_YYYY-MM-DD.txt
ieee/
ieee_v1.0_YYYY-MM-DD.csv
ieee_v1.0_query_YYYY-MM-DD.txt
processed/
all_records_before_dedup.csv
deduplication_log.csv
records_deduplicated.csv

screening/
calibration_day3.csv
calibration_day3.md
exclusion_codes.md
decision_log.csv
```

27. Gate metodologico do Dia 4

- ☐ protocolo v1.0 confirmado antes da busca
- ☐ string final Scopus executada sem alteracoes
- ☐ data/hora da busca Scopus registrada
- ☐ numero definitivo da Scopus registrado
- ☐ export bruto Scopus preservado
- ☐ string final IEEE executada sem alteracoes
- ☐ data/hora da busca IEEE registrada
- ☐ numero definitivo do IEEE registrado
- ☐ export bruto IEEE preservado
- ☐ search_log.csv atualizado
- ☐ exports brutos preservados sem edicao
- ☐ Scopus + IEEE consolidados

- [] duplicatas identificadas
- [] deduplicacao documentada
- [] IDs R0001... atribuidos
- [] records_deduplicated.csv criado
- [] decision_log.csv preparado

28. Sequencia pratica recomendada

```
ETAPA 1
Executar busca definitiva na Scopus.
->
Registrar o novo total.

ETAPA 2
Exportar CSV da Scopus e conferir estrutura.

ETAPA 3
Executar busca definitiva no IEEE Xplore.
->
Registrar o novo total.

ETAPA 4
Exportar CSV do IEEE e conferir estrutura.

ETAPA 5
Consolidar e deduplicar os dois arquivos sem alterar os arquivos brutos.

ETAPA 6
Gerar:
all_records_before_dedup.csv
deduplication_log.csv
records_deduplicated.csv

ETAPA 7
Preparar decision_log.csv.

ETAPA 8
Iniciar screening formal por titulo e resumo.
```

Resumo do Dia 4

```
BUSCA DEFINITIVA
->
EXPORTACAO BRUTA
->
SEARCH LOG
->
CONSOLIDACAO
->
DEDUPLICACAO
->
IDS DOS REGISTROS
->
BASE FINAL PARA SCREENING
```

Primeiro passo: executar a busca definitiva na Scopus com a string v1.0 congelada. Depois, registrar o novo numero de resultados e exportar o CSV bruto.